

Elementy Statystycznego Uczenia Maszynowego

Modele Gaussowskie

Wielowymiarowy rozkład normalny

Powtórka z rachunku prawdopodobieństwa:

- Jeśli $\mathbf{x} = [x_1, x_2, \dots, x_d]^\top$ ma wielowymiarowy rozkład normalny (*Multivariate Normal distribution – MVN*) z wartością oczekiwaną $\boldsymbol{\mu}$ i macierzą kowariancji $\boldsymbol{\Sigma}$ to:

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right]$$

Co możemy wyrazić skrótowo:

$$\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

- Ponadto:

$$\boldsymbol{\Lambda} := \boldsymbol{\Sigma}^{-1} \quad - \text{macierz precyzji.}$$

Wnioskowanie w łącznym rozkładzie MVN

Niech

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_k \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_l \end{bmatrix}$$

mają łącznie rozkład normalny:

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

z parametrami:

$$\boldsymbol{\mu} = \begin{bmatrix} \mu_{\mathbf{x}} \\ \mu_{\mathbf{y}} \end{bmatrix}, \quad \boldsymbol{\Sigma} = \begin{bmatrix} \Sigma_{\mathbf{xx}} & \Sigma_{\mathbf{xy}} \\ \Sigma_{\mathbf{yx}} & \Sigma_{\mathbf{yy}} \end{bmatrix}, \quad \boldsymbol{\Lambda} = \boldsymbol{\Sigma}^{-1} = \begin{bmatrix} \Lambda_{\mathbf{xx}} & \Lambda_{\mathbf{xy}} \\ \Lambda_{\mathbf{yx}} & \Lambda_{\mathbf{yy}} \end{bmatrix}$$

Wnioskowanie w łącznym rozkładzie MVN

Wówczas:

- Rozkłady brzegowe są rozkładami normalnymi:

$$\mathbf{x} \sim N(\boldsymbol{\mu}_{\mathbf{x}}, \boldsymbol{\Sigma}_{\mathbf{xx}}),$$

$$\mathbf{y} \sim N(\boldsymbol{\mu}_{\mathbf{y}}, \boldsymbol{\Sigma}_{\mathbf{yy}})$$

Wnioskowanie w łącznym rozkładzie MVN

Wówczas:

- Rozkłady warunkowe są rozkładami normalnymi:

$$\mathbf{x} \mid \mathbf{y} \sim N \left(\boldsymbol{\mu}_{\mathbf{x}|\mathbf{y}}, \boldsymbol{\Sigma}_{\mathbf{x}|\mathbf{y}} \right),$$

gdzie:

$$\begin{aligned} \boldsymbol{\Sigma}_{\mathbf{x}|\mathbf{y}} &= \boldsymbol{\Sigma}_{\mathbf{xx}} - \boldsymbol{\Sigma}_{\mathbf{xy}} \boldsymbol{\Sigma}_{\mathbf{yy}}^{-1} \boldsymbol{\Sigma}_{\mathbf{yx}} \\ &= \boldsymbol{\Lambda}_{\mathbf{xx}}^{-1} \end{aligned}$$

$$\begin{aligned} \boldsymbol{\mu}_{\mathbf{x}|\mathbf{y}} &= \boldsymbol{\mu}_{\mathbf{x}} + \boldsymbol{\Sigma}_{\mathbf{xy}} \boldsymbol{\Sigma}_{\mathbf{yy}}^{-1} (\mathbf{y} - \boldsymbol{\mu}_{\mathbf{y}}) \\ &= \boldsymbol{\Sigma}_{\mathbf{x}|\mathbf{y}} \left(\boldsymbol{\Lambda}_{\mathbf{xx}} \boldsymbol{\mu}_{\mathbf{x}} - \boldsymbol{\Lambda}_{\mathbf{xy}} (\mathbf{y} - \boldsymbol{\mu}_{\mathbf{y}}) \right) \end{aligned}$$

Liniowe modele Gaussowskie

Powyższe własności rozkładów łącznych pozwalają wnioskować (jawnie) w *liniowych modelach Gaussowskich* (*Linear Gaussian Models*).

Niech $\mathbf{x} = [x_1, x_2, \dots, x_k]^T$ będzie pewną zmienną ukrytą (nieobserwowaną), zaś:

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b} + \epsilon$$

jej pomiarem. Zakładamy, że pomiar dokonany jest ze (znaną) precyzją $\Sigma_{\mathbf{y}}^{-1}$:

$$\epsilon \sim N(\mathbf{0}, \Sigma_{\mathbf{y}})$$

Ponadto zakładamy, że macierz $\mathbf{A}_{l \times k}$ oraz wektor $\mathbf{b}_{l \times 1}$ są znane.

Liniowe modele Gaussowskie

Przy tych założeniach wiarygodność ma postać:

$$p(\mathbf{y} \mid \mathbf{x}) = N(\mathbf{Ax} + \mathbf{b}, \Sigma_{\mathbf{y}})$$

Dalej, przyjmijmy rozkład normalny jako rozkład a priori dla \mathbf{x} (w tym przypadku jest to rozkład sprzężony do wiarygodności):

$$\mathbf{x} \sim N(\mu_{\mathbf{x}}, \Sigma_{\mathbf{x}})$$

Pytanie brzmi: jaką postać ma rozkład a posteriori $p(\mathbf{x} \mid \mathbf{y})$?

Jest to klasyczny przykład liniowego modelu Gaussowskiego.

Linowe modele Gaussowskie

Formalnie, mamy model postaci:

$$\mathbf{x} \sim N(\mu_{\mathbf{x}}, \Sigma_{\mathbf{x}})$$

$$\mathbf{y} \mid \mathbf{x} \sim N(\mathbf{A}\mathbf{x} + \mathbf{b}, \Sigma_{\mathbf{y}})$$

Wówczas (korzystając z rozkładu warunkowego w MVN) otrzymujemy rozkład a posteriori postaci

$$\mathbf{x} \mid \mathbf{y} \sim N(\mu_{\mathbf{x}|\mathbf{y}}, \Sigma_{\mathbf{x}|\mathbf{y}})$$

gdzie:

$$\Sigma_{\mathbf{x}|\mathbf{y}} = [\Sigma_{\mathbf{x}}^{-1} + \mathbf{A}^T \Sigma_{\mathbf{y}}^{-1} \mathbf{A}]^{-1}$$

$$\mu_{\mathbf{x}|\mathbf{y}} = \Sigma_{\mathbf{x}|\mathbf{y}} [\mathbf{A}^T \Sigma_{\mathbf{y}}^{-1} (\mathbf{y} - \mathbf{b}) + \Sigma_{\mathbf{x}}^{-1} \mu_{\mathbf{x}}]$$